

SpamKiller

Yapay Zeka Destekli Türkçe Spam E-posta Tespit Sistemi

Hedef

SpamKiller, Türkçe e-posta içeriklerini ve ortalama (phishing) saldırılarını spam veya gerçek olarak sınıflandıran yapay zeka destekli bir sistemdir. Projenin temel amacı, klasik makine öğrenmesi yöntemleri ile Türkçe dil modeli BERTurk'ü aynı veri üzerinde karşılaştırarak Türkçe metinlerde hangi yaklaşımın daha başarılı olduğunu ölçmektir.

Veri Seti

Temel veri seti olarak *UCI SMS Spam Collection Dataset* kullanılacaktır. Türkçe kapsam şu iki yolla genişletilecektir:

- Machine translation* ile mevcut kayıtların Türkçeye çevrilmesi
- Banka dolandırıcılığı, sahte kargo bildirimi gibi Türkiye'ye özgü spam kalıplarının elle oluşturulması

Metodoloji

Ham metinler modele sunulmadan önce gereksiz kelimelerden (stopword) arındırılacak ve zemberek-python kütüphanesi ile morfolojik analizden geçirilerek kelime köklerine ulaşılabilecektir. E-posta ve URL adresleri ise modele daha temiz bir girdi sağlamak amacıyla özel etiketlerle normalize edilecektir. Özellik çıkarımı aşamasında Logistic Regression ve Random Forest gibi klasik modeller için TF-IDF vektörizasyonu, BERTurk için ise kendi tokenizer'ı ile cümle gömmeleri (embeddings) kullanılacaktır. Modellerin performansı; Accuracy, Precision, Recall ve temel metrik olarak F1-Score üzerinden değerlendirilecektir.

Arayüz (Streamlit)

Karşılaştırmalar sonucunda en yüksek F1-Score'u elde eden model, Streamlit tabanlı bir web arayüzüne entegre edilecektir. Kullanıcılar bu arayüzdeki metin alanına e-postalarını yapıştırarak analizi başlatabilecek; sistem de kullanıcılara spam veya gerçek etiketini, modelin tahminindeki güven skorunu ve kararı etkileyen şüpheli kelimelerin metin içindeki vurgulanmış halini sunacaktır.

Beklenen Sonuç

Proje sonucunda, Türkçe metinlerin bağlamını ve morfolojisini anlama kapasitesine sahip olan BERTurk modelinin, TF-IDF temelli klasik yöntemlere kıyasla daha yüksek bir başarı (F1-Score) göstermesi öngörülmektedir. Nihai olarak, bu modelin entegre edildiği web uygulaması sayesinde kullanıcıları ortalama saldırılarına karşı koruyan ve verdiği "spam" kararının nedenlerini metin üzerindeki anahtar kelimeleri vurgulayarak açıklayabilen şeffaf bir güvenlik aracı elde edilecektir.

Kaynaklar

- UCI SMS Spam Collection Dataset
- BERTurk — <https://huggingface.co/dbmdz/bert-base-turkish-cased>
- Streamlit — <https://streamlit.io>
- zemberek-python — <https://github.com/Loodos/zemberek-python>